Step2 2 주차 결과보고서

sEMG 전처리와 25 차원 특징 추출

오성빈 2026 10 16

손동작 4 종과 팔꿈치 각도 2 종을 동시에 구분하기 위한 데이터 준비 단계이다. 1 주차의 데이터 구조와 8 클래스 설계를 이어받아, 실제 CSV 에서 시행을 나누고 시간영역 특징을 추출한 뒤 표준화된 학습·테스트 데이터셋을 생성했다. 추가 분석에서는 학습 시행만 사용해 분석 구간과 기록 시간에 따른 특징의 안정성을 점검했다. 구간 이동에 대한 민감도는 특징마다 달랐고, 기록 후반의 변화 방향도 기록별로 달랐다.

항목	실행 결과
원자료	8 명 × 8 조건 = 64 개 연속 기록
시행	1,920 개, 클래스당 240 개
분석 구간	마커 기준 1.5~3.5 초, 2,000 표본 × 5 채널
윈도우	200 ms / 100 ms 간격 / 시행당 19 개
특징	RMS·MAV·WL·ZC·SSC × 5 채널 = 25 차원
학습 / 테스트	29,184 / 7,296 개 윈도우
확인 결과	시행 ID 중복 0 건, 표준화 검증 통과, 단위 테스트 5 개 통과

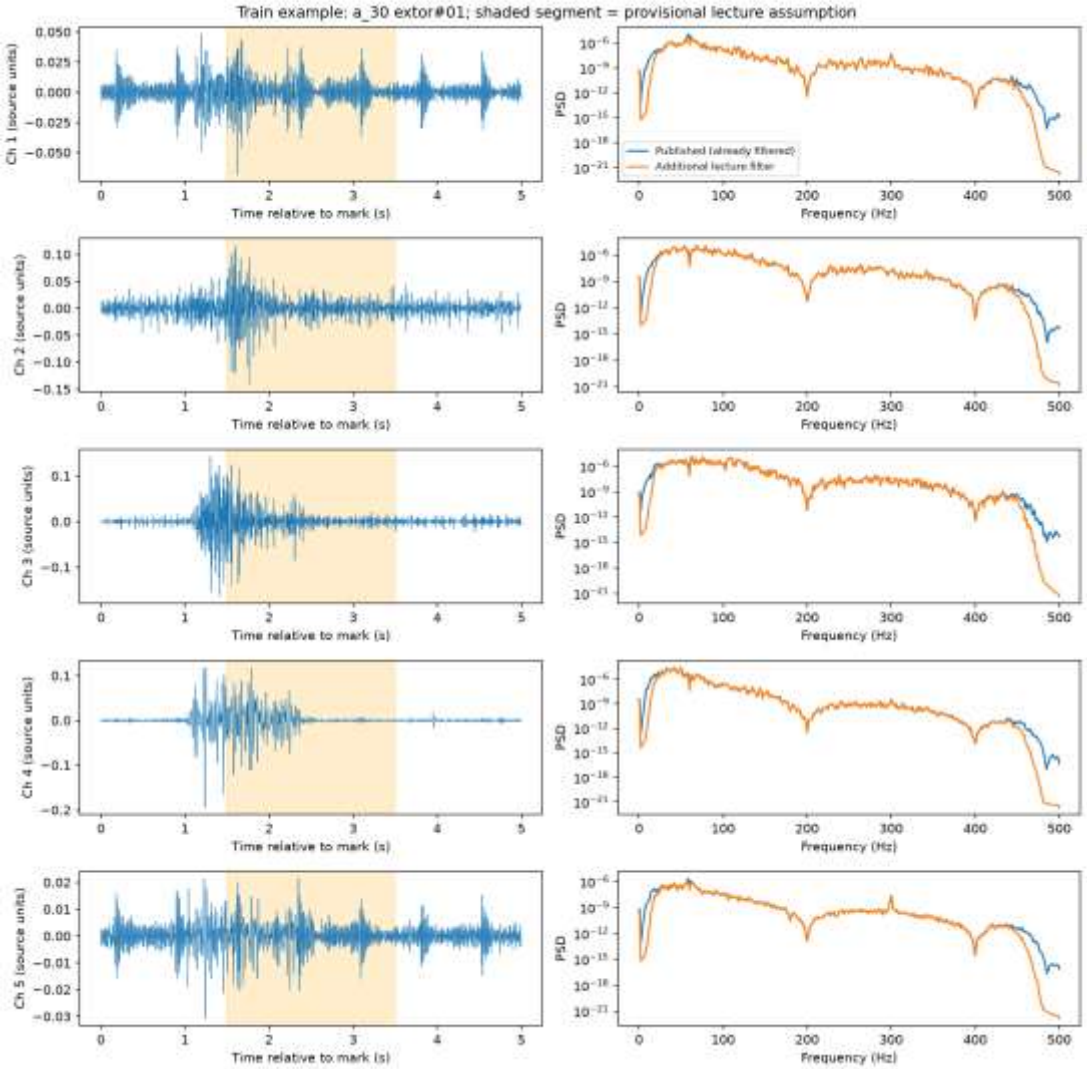
해석 범위

공개 신호에는 이미 필터가 적용되어 있다. 기본 데이터셋은 이를 그대로 사용하고, 추가 필터의 효과는 별도 실습으로 비교했다. 1.5~3.5 초는 강의의 잠정 설정이며 마커와 실제 동작 시점의 정렬은 확인되지 않았다. 이번 보고서는 모델 학습이나 성능 비교 결과를 포함하지 않는다.

수록 항목: ① 필터 검증 ② 윈도우 확인 ③ 특징 구현 코드
④ 시행 우선 분할 코드 ⑤ 데이터셋 요약 ⑥ 설정 근거

① 필터 검증 추가 필터 전후 비교

원자료 설명에 따르면 60 Hz notch 및 20~450 Hz 4 차 Butterworth 가 이미 적용되어 있다. 아래의 "전"은 공개된 필터 처리 신호, "후"는 Q=30 notch 와 대역통과 필터를 filtfilt 로 한 번 더 적용한 결과다. 무필터 원신호와의 비교가 아니다. 학습 시행 a_30 extor#01 을 예시로 사용했다.



왼쪽: 공개 신호와 잠정 분석 구간(주황색). 오른쪽: 공개 신호(파랑)와 추가 필터 결과(주황)의 PSD. Welch 방법, fs=1,000 Hz, nperseg=1,000.

채널	추가 필터 전 표준편차	추가 필터 후 표준편차
bandpass 1	0.009820	0.008496
bandpass 2	0.017901	0.017472
bandpass 3	0.019422	0.018874
bandpass 4	0.020949	0.019948
bandpass 5	0.004824	0.004235

추가 필터는 스펙트럼과 진폭에 변화를 준다. 중복 필터링을 피하기 위해 최종 dataset.npz 에는 already-filtered 모드를 사용했다. 이 비교만으로 분류 성능 개선을 주장할 수 없다.

② 윈도우 확인 ③ 특징 구현 코드

실제 실행 출력

```
Python execution | a_30 extor.csv | trial #01
sampling_rate = 1000 Hz
segment_start = mark + 1500 samples
segment.shape = (2000, 5)
windows.shape = (19, 200, 5)
features.shape = (19, 25)
window_start_offsets = [0, 100, 200, 300, 400, 500, 600, 700, 800, 900, 1000,
  1100, 1200, 1300, 1400, 1500, 1600, 1700, 1800]
finite_features = True
```

실제 CSV 를 다시 읽어 생성한 출력 문자열을 가독성을 위해 이미지로 표시했다. 2 초 구간 → (19, 200, 5) 윈도우 → (19, 25) 특징 배열이 확인된다.

td_features 함수 전체 week2 py

```
def td_features(w, th=0.01):
    """Feature-major order; SSC has no amplitude threshold, as in lecture."""
    w = np.asarray(w, dtype=np.float64)
    if w.shape != (WIN, 5) or not np.isfinite(w).all():
        raise ValueError("Expected finite (200, 5) window")
    rms = np.sqrt(np.mean(w ** 2, axis=0))
    mav = np.mean(np.abs(w), axis=0)
    d = np.diff(w, axis=0)
    wl = np.sum(np.abs(d), axis=0)
    zc = np.sum(((w[:-1] * w[1:]) < 0) & (np.abs(d) >= th), axis=0)
    ssc = np.sum((d[:-1] * d[1:]) < 0, axis=0)
    return np.concatenate([rms, mav, wl, zc, ssc])
```

특징 순서는 RMS 5 채널 → MAV 5 채널 → WL 5 채널 → ZC 5 채널 → SSC 5 채널이다. ZC 는 부호 변화와 표본 차이 ≥ 0.01 을 함께 요구한다. SSC 는 강의 코드처럼 진폭 문턱값을 적용하지 않는다.

전체 창·채널 평균 ZC: 문턱값 0 일 때 25.6428 회, 0.01 일 때 5.9068 회. 이는 작은 교차의 제거 효과이며 모델 성능 비교 수치는 아니다.

④ 분할 코드 시행을 먼저 나누기

CSV 한 개에는 시행 30 개가 들어 있다. 파일명과 마커 순번으로 시행 ID 를 만들고 클래스 비율을 유지하면서 80:20 으로 먼저 분할한다. 동일 시행의 중첩 윈도우가 학습·테스트에 흩어지지 않게 하기 위한 처리다.

```
def split_trials(trials, seed=42):
    train, test = train_test_split(np.arange(len(trials)), test_size=0.2,
                                   stratify=trials.y, random_state=seed)
    result = trials.copy()
    result['split'] = 'train'
    result.loc[test, 'split'] = 'test'
    assert set(result.loc[train, 'trial_id']).isdisjoint(result.loc[test, 'trial_id'])
    return result
```

실제 처리 순서 중 핵심 부분

```
trials, source_files = inventory(data_dir)
trials = split_trials(trials, seed)  # FIRST: split trial IDs

# Later, inside the loop over each trial:
segment = processed[segment_start:segment_start + 2000]
trial_windows = windows(segment)
for number, w in enumerate(trial_windows):
    features.append(td_features(w))
    # Save row.split together with every window.

# After collecting features, fit ONLY on training rows:
Xtr_raw, Xte_raw = X[train_mask], X[~train_mask]
scaler = StandardScaler().fit(Xtr_raw)
Xtr = scaler.transform(Xtr_raw)
Xte = scaler.transform(Xte_raw)
```

위 블록은 week2.py 의 처리 순서를 발췌·축약하고 설명 주석을 덧붙인 것이다. 분할 함수는 원문 전체를 수록했다. seed=42, stratify=클래스, test_size=0.2 를 사용했다.

검증 항목	결과
학습 / 테스트 시행	1,536 / 384
공유 시행 ID	0 개
표준화 fit 대상	학습 특징만
최대 |학습 평균|	1.845e-14
최대 |학습 표준편차 - 1|	1.180e-13

한계 및 다음 단계

같은 피험자·연속 기록의 서로 다른 시행은 양쪽에 포함된다. 따라서 새 피험자에 대한 일반화 평가가 아니다. 3 주차 교차검증은 Xtr_raw 와 groups_tr 로 시행 그룹을 보존하고, 각 fold 안에서 스케일러를 학습해야 한다.

⑤ 데이터셋 요약 샘플 수와 클래스 분포

구분	시행 수	윈도우 수	특징 차원
학습	1,536	29,184	25
테스트	384	7,296	25
전체	1,920	36,480	25

클래스별 분포

클래스	학습 시행	테스트 시행	학습 창	테스트 창
30_fist	192	48	3648	912
30_open	192	48	3648	912
30_pronation	192	48	3648	912
30_supination	192	48	3648	912
60_fist	192	48	3648	912
60_open	192	48	3648	912
60_pronation	192	48	3648	912
60_supination	192	48	3648	912

30/60 은 팔꿈치 각도(도), fist 는 주먹 쥐기, open 은 손 펴기, pronation 은 회내, supination 은 회외이다. 원자료 파일명 pro/extor 를 각각 pronation/supination 으로 대응시켰다.

저장 결과

outputs/week2/dataset.npz 에는 Xtr, ytr, Xte, yte 를 저장했다. 추가로 표준화 전 특징(Xtr_raw, Xte_raw), 시행 그룹(groups_tr, groups_te), 피험자 ID, 클래스·특징 이름, 스케일러 평균·스케일·분산을 함께 저장했다.

trials.csv 와 windows.csv 에는 시행과 창의 원본 파일 및 표본 위치가 기록된다. summary.json 에는 입력 파일 SHA-256 과 설정, environment.json 에는 실제 실행 패키지 버전이 남는다. 노트북의 코드 셀 8 개가 모두 오류 없이 실행되었다.

독립 표본 수의 해석

중첩된 창은 서로 상관되어 있다. 36,480 개 창을 36,480 번의 독립 시행으로 해석하지 않는다. 모델 평가와 통계 검정에서는 시행·피험자 구조를 고려해야 한다.

⑥ 설정 근거와 최종 정리

윈도우 200 ms 를 선택한 이유

200 ms 창은 짧은 시간 구간의 근활성 특징을 계산하면서 동작의 시간 변화를 추적하기 위해 선택했다. 너무 짧은 창의 특징 불안정성과 너무 긴 창의 시간 정보 손실을 절충하는 강의 설정이며, 이번 실습에서 최적 길이를 비교 검증한 것은 아니다.

오버랩 50 를 선택한 이유

50% 중첩은 100 ms 마다 특징을 생성하여 창 경계 부근의 변화가 누락되는 것을 줄이기 위해 선택했다. 인접 창 사이에 상관이 생기므로 시행을 먼저 분할하고 이후 교차검증에서도 같은 시행의 창을 하나의 그룹으로 유지해야 한다.

최종 결과

64 개 기록의 1,920 개 시행에서 25 차원 특징 데이터셋을 생성했다. 시행 ID 중복과 표준화 통계, 특징 수식·문턱값·창 경계·분할·필터 동작을 검증했으며 단위 테스트 5 개가 통과했다. 3 주차의 SVM·Random Forest·XGBoost 학습에 사용할 수 있는 데이터와 추적 정보를 준비했다.

남은 확인 사항

마커와 실제 동작의 정렬, 원 논문의 정확한 2 초 시작점, ZC·SSC 정의는 추가 확인이 필요하다. 분석 구간과 추가 필터 설정은 보고서에 명시한 실습 조건이며 논문의 모든 세부 설정을 재현했다고 주장하지 않는다.

7 분석 구간과 기록 시간에 따른 특징의 안정성

분석 목적과 범위

기존 1.5~3.5 초 분석 구간이 특징에 미치는 영향과 한 기록 안에서 반복 순서에 따라 특징이 달라지는지를 탐색했다. 기존 분할의 학습 시행 1,536 개만 사용했으며 테스트 시행 384 개는 이번 추가 분석에 사용하지 않았다. 공개 신호에 추가 필터를 적용하지 않았고 기본 dataset.npz 와 분할 설정도 변경하지 않았다.

분석 단위와 집계 방법

8 명 × 8 조건의 64 개 기록에서 각 시행의 2 초 구간을 19 개 창으로 나누고, 창별 25 차원 특징의 산술평균을 시행 대표값으로 사용했다. 중첩 창을 독립 관측치로 세지 않았다. 기록마다 학습 시행 수가 다르므로 기록 안에서 먼저 요약하고 64 개 기록에 동일한 가중치를 주었다. 같은 사람의 기록들은 독립적이지 않으므로 아래 결과는 기술통계이며 유의성 검정이나 모집단 추론 결과가 아니다.

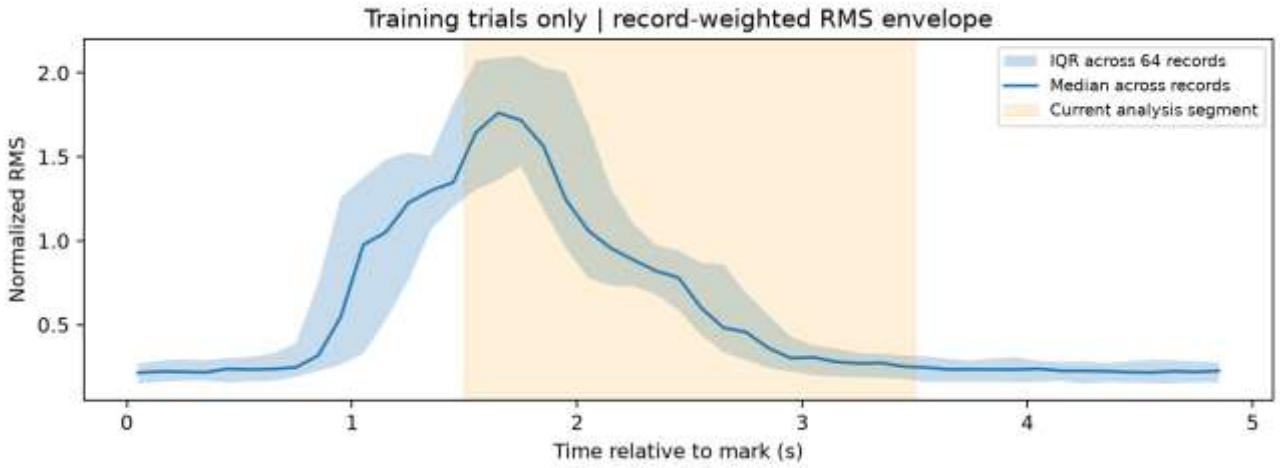


그림 1 마커 이후 정규화 RMS 변화

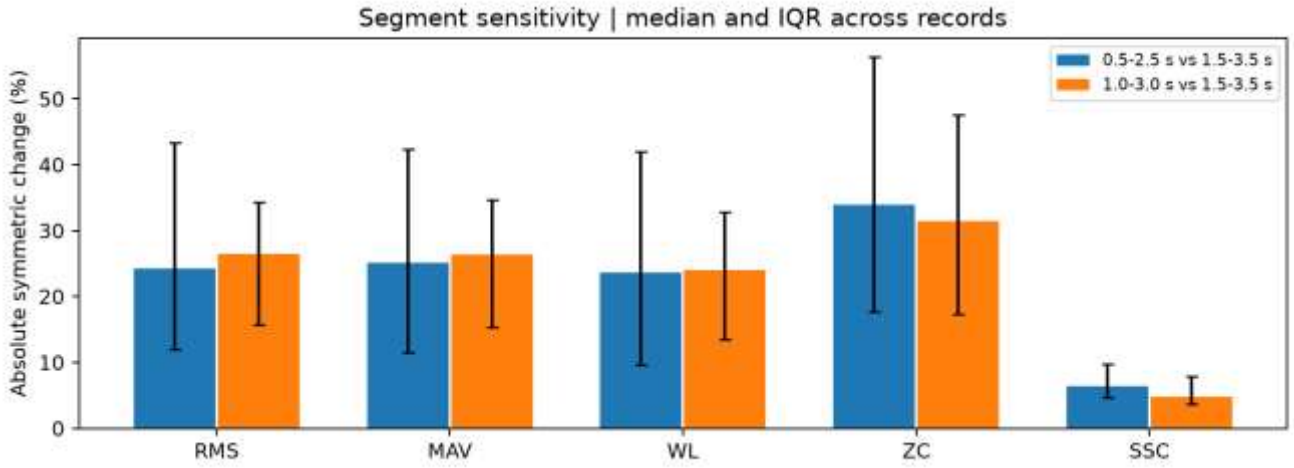
각 시행의 첫 4.9 초를 100 ms 비중첩 구간 49 개로 나누고 채널별 RMS 를 계산했다. 각 값을 동일 시행·채널의 4.9 초 전체 RMS 로 나눈 뒤 채널 중앙값 → 기록 내 시행 중앙값 → 기록 간 중앙값 순서로 집계했다. 음영은 기록 간 25~75 백분위 범위이며 신뢰구간이 아니다.

중앙값 곡선의 최대값은 중심 시각 1.65 초인 구간에서 나타났다. 이는 현재 분석 구간의 앞부분에 상대적으로 높은 활성이 나타난다는 관찰이며, 실제 동작 시작 시점이나 최적 분석 구간을 확정하는 근거는 아니다. 정규화는 시간 양상을 비교하기 위한 것으로 절대 진폭의 사람 간 차이를 보여주지 않는다.

8 분석 구간 이동에 대한 특징 민감도

같은 학습 시행에서 0.5~2.5 초, 1.0~3.0 초, 기존 1.5~3.5 초를 비교했다. 길이와 창 수를 같게 유지하여 구간 위치의 영향을 살폈다. 기준 구간과의 차이는 대칭 변화율의 절댓값으로 계산했다.

절대 대칭 변화율 = 200 × |비교값 - 기준값| / (|비교값| + |기준값|). 두 값이 모두 0 이면 0 으로 정의했다. 단위는 %이고 범위는 0~200 이며, 기준값을 분모로 쓰는 일반적인 증가율과 다르다.



특징	0.5~2.5 초 비교	1.0~3.0 초 비교
RMS	24.22 [12.02, 43.37]	26.51 [15.68, 34.24]
MAV	25.14 [11.47, 42.39]	26.40 [15.26, 34.63]
WL	23.63 [9.64, 41.94]	23.93 [13.43, 32.84]
ZC	33.87 [17.65, 56.35]	31.44 [17.31, 47.53]
SSC	6.43 [4.59, 9.77]	4.72 [3.60, 7.86]

표 1 값은 64 개 기록의 중앙값 [25 백분위, 75 백분위]이다. 시행·채널별 변화율을 먼저 계산하고, 기록 내 시행 중앙값 → 5 채널 중앙값으로 기록 대표값을 만들었다. 그림의 오차 막대는 기록 간 사분위 범위다.

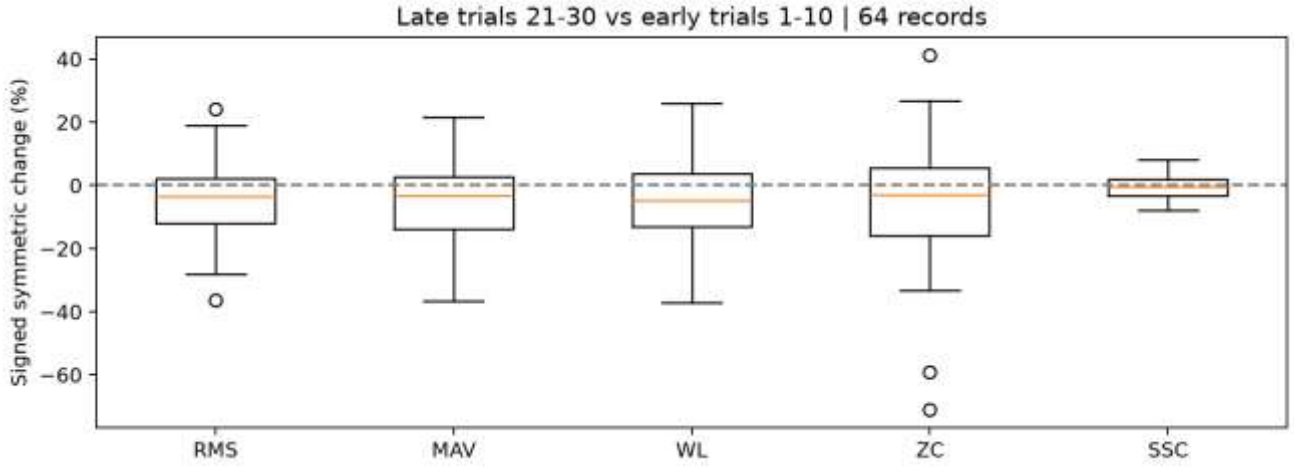
ZC 의 변화 중앙값은 약 31~34%, RMS·MAV·WL 은 약 24~27%인 반면 SSC 는 약 5~6%였다. 이 집계에서 SSC 는 구간 이동에 상대적으로 덜 민감했지만, 낮은 민감도가 높은 분류 성능을 뜻하지는 않는다. ZC 의 0.01 문턱값은 구간별 진폭 변화와 함께 교차 수에 영향을 줄 수 있다.

0.5 초만 이동한 비교에서도 1 초 이동보다 RMS 변화가 더 작지는 않았다. 따라서 구간 이동량과 특징 변화 크기를 단순 비례로 가정할 수 없다. 이번 탐색만으로 기본 구간을 교체하지 않고, 후속 학습 데이터 내부 검증에서 후보 구간의 성능과 안정성을 함께 평가할 필요가 있다.

9 기록 초반과 후반의 특징 변화

원래 시행 순번 1~10 회를 초반, 11~20 회를 중반, 21~30 회를 후반으로 정의했다. 학습 데이터에 포함된 시행만 사용했으므로 실제 집계 수는 초반 509 개, 중반 520 개, 후반 507 개였다. 기록별 포함 수는 초반·후반 각각 5~10 개, 중반 4~10 개이며, 아래 변화량은 후반과 초반의 비교다. 중반은 분할 현황만 제시하며 단조로운 추세를 검증하지 않았다.

기존 1.5~3.5 초의 시행 대표 특징을 기록·단계별로 중앙값 집계했다. 채널별 부호 있는 대칭 변화율 200 × (후반 - 초반) / (|후반| + |초반|)을 구한 다음 5 채널 중앙값을 기록 대표 변화량으로 사용했다. 두 값이 모두 0 인 경우는 0 으로 처리했다.



특징	중앙값 [25%, 75%]	증가 기록	감소 기록	변화 0
RMS	-3.53 [-12.12, 2.09]	21	43	0
MAV	-3.12 [-13.98, 2.67]	21	43	0
WL	-4.72 [-13.16, 3.86]	22	42	0
ZC	-3.07 [-16.03, 5.60]	22	39	3
SSC	-0.38 [-3.28, 2.04]	27	35	2

표 2 변화율 단위는 %이며 각 행은 64 개 기록을 요약한다. 그림의 상자는 사분위 범위, 가운데 선은 중앙값, 수염은 1.5 IQR 이내 값이고 바깥 점은 그 범위를 벗어난 기록이다. 이 점을 오류 데이터로 판정하거나 제거하지 않았다.

RMS 변화의 중앙값은 -3.53%이고 64 개 기록 중 43 개에서 감소, 21 개에서 증가했다. 사분위 범위는 -12.12~2.09%로 0 을 포함하므로 모든 기록에 동일한 방향의 변화가 있다고 해석할 수 없다. 이 비교는 통계적 유의성 검정이 아니며 근피로의 증거로 단정하지 않는다.

10 추가 분석의 결론과 다음 실험

분석 구간을 고정하는 이유

동일 시행이라도 구간 위치를 바꾸면 진폭 기반 특징과 ZC 가 달라졌다. 결과를 비교할 때는 구간 시작점, 길이, 필터와 문턱값을 함께 기록해야 한다. 현재 구간을 최적이라고 주장하지 않고, 후보 선택은 학습 데이터 내부의 시행 그룹 교차검증에서 수행한 뒤 최종 테스트를 한 번 적용한다.

기록 순서를 보존하는 평가

초반과 후반의 변화 방향과 크기가 기록마다 달랐다. 기존 무작위 시행 분할만으로 시간에 따른 성능 유지 여부를 알 수 없으므로, 후속 실험에서는 기록 초반으로 학습하고 후반을 평가하는 시간 순서 분할을 별도 설정으로 비교할 수 있다. 이 경우 기존 80:20 결과와 학습·평가 범위가 달라지므로 직접 같은 조건의 성능으로 취급하지 않는다.

해석상의 한계

64 개 기록은 8 명의 반복 측정이며 독립적인 피험자 64 명을 의미하지 않는다. 기록·채널 중앙값은 일부 채널과 특정 동작의 큰 변화를 가릴 수 있다. 이번 결과는 정해진 세 구간과 초반·후반 차이에 한정되며, 실제 동작 정렬이나 단조로운 시간 추세, 근피로·자세 변화·전극 상태 중 어떤 원인이 작용했는지를 구분하지 못한다.

추가로 확인할 실험

다음 단계에서는 피험자·클래스·채널별 결과를 분리해 변화가 집중되는 조건을 찾고, 구간별 분류 성능과 안정성을 함께 평가한다. ZC 는 문턱값 변화에 대한 민감도도 확인한다. 새 피험자에 대한 적용이 목표라면 동일 피험자의 기록이 양쪽에 섞이지 않는 피험자 단위 평가를 별도로 설계한다.

분석 재현과 산출물

analyze_stability.py 는 기존 trials.csv 의 train 행만 선택한다. 실행 명령은 python analyze_stability.py 이며 원본 데이터 위치와 환경은 기존 보고서의 재현 방법과 같다. outputs/stability 에 시행별 특징, 구간별 요약, 기록별 시간 변화, 단계별 시행 수와 그림 3 개를 저장했다. 기본 학습·테스트 데이터셋은 변경하지 않았다.

추가 근거 자료: outputs/stability/summary.json, segment_summary.csv, record_time_changes.csv, phase_counts.csv 및 trial_features.csv